



- **minimax risk 是什么?**

所有可能的 estimator 在最坏的数据分布情况下所能达到的最小预期误差;

- **为什么要研究 minimax risk?**

理解统计 (参数) 估计的性能极限;

- **如何得到 minimax risk 的下界?**

Le Cam, Fano;





What is minimax risk?


在解决经典的 estimation problems 时，我们使用 minimax risk 的标准版本。在涉及优化问题时，我们将引入一个更广泛的版本：minimax excess risk。

令 $\mathcal{P}$ 表示样本空间 $\mathcal{X}$ 上的一族分布， $\theta: \mathcal{P} \rightarrow \Theta$ 是 $\mathcal{P}$ 上的函数，将分布 P 映射为参数 $\theta(P)$ 。目标是根据从未知分布 P 中采样得到的 X_i 估计 $\theta(P)$ 。有时 $\theta(P)$ 唯一确定 P ，有时不然，但至少揭示了关于 P 的一些信息。

为了衡量参数估计的好坏，定义 $\rho: \Theta \times \Theta \rightarrow \mathbb{R}_+$ 为 Θ 上的（半）范数，并令 $\Phi: \mathbb{R}_+ \rightarrow \mathbb{R}_+$ 为满足 $\Phi(0) = 0$ 的不减函数。对于一个分布 P ，假设 X_i 是服从 P 的 i.i.d.。对于一个给定的估计方式 $\hat{\theta}: \mathcal{X}^n \rightarrow \Theta$ ，我们用以下风险衡量 $\hat{\theta}(X_1, \dots, X_n)$ 的好坏：

$$\mathbb{E}_P \left[\Phi \left(\rho \left(\hat{\theta}(X_1, \dots, X_n), \theta(P) \right) \right) \right] \quad (6.1)$$

比如，当 $\rho(\theta, \theta') = |\theta - \theta'|$, $\Phi(t) = t^2$ 时，此时的风险就是均方误差。通过上式，我们得到了关于问题的 risk functional。





- 从单个 P 到一族 P (取 sup / Bayesian)

对于任何固定的 P , 总存在一个平凡的 $\hat{\theta}$: 直接返回 $\theta(P)$ 就可以最小化风险。所以, 我们不想把 risk functional 停留在 pointwise sense (即只对某个固定的 P), 而要考虑所有可能分布。一种做法是 Bayesian, 在 $\mathcal{P}$ 上放置一个先验的概率分布 π , 把 $\theta(P)$ 视为 P 服从分布 π 的随机变量。这里采用另一种方法, 将衡量 $\hat{\theta}$ 的 risk 改写为

$$\sup_{P \in \mathcal{P}} \mathbb{E}_P \left[\Phi \left(\rho \left(\hat{\theta}(X_1, \dots, X_n), \theta(P) \right) \right) \right] \quad (6.2)$$

使得上式最小的估计方式 θ 给出了 minimax risk 的标准定义:

$$\mathcal{M}_n(\theta(P), \Phi \circ \rho) = \inf_{\hat{\theta}} \sup_{P \in \mathcal{P}} \mathbb{E}_P \left[\Phi \left(\rho \left(\hat{\theta}(X_1, \dots, X_n), \theta(P) \right) \right) \right] \quad (6.3)$$





- 从 minimax risk 到 minimax excess risk:

当问题从**参数估计**变成**优化与预测**时，需要引入 minimax excess risk，因为问题本身有复杂度，即使是完美的上帝视角模型也会犯错；

在有些问题中，我们假设存在某个 loss function $l: \Theta \times \mathcal{X} \rightarrow \mathbb{R}$ ，对于任何观测 $x \in \mathcal{X}$ ， $l(\theta; x)$ 衡量了使用 θ 作为估计方法的误差。在此情况下，定义 population loss:

$$L_P(\theta) = \mathbb{E}_P[l(\theta; X)] = \int_{\mathcal{X}} l(\theta; X) dP(x) \quad (6.4)$$

一个例子是 Support Vector Machine。在线性分类问题中，我们观察到数据对 $z = (x, y)$ ，其中 $y \in \{-1, 1\}$, $x \in \mathbb{R}^d$ ，目标是寻找一个参数 $\theta \in \mathbb{R}^d$ ，使得 $\text{sign}(\langle \theta, x \rangle) = y$ 。Hinge loss $(\theta; z) = [1 - y\langle \theta, x \rangle]_+$ 是一个自然的凸替代函数；在集合 $\Theta = \{\theta \in \mathbb{R}^d : \|\theta\|_2 \leq r\}$ 上最小化相关的 risk functional 即可得到 SVM。





What is minimax excess risk?

- 从 minimax risk 到 minimax excess risk:


对于给定样本 $X_1, \dots, X_n$ 的一个（可能是随机的）估计器 $\hat{\theta} : \mathcal{X}^n \rightarrow \Theta$ ，我们将针对 $\mathcal{P}$ 的 maximum excess risk 定义为：

$$\sup_{P \in \mathcal{P}} \left\{ \mathbb{E}_P \left[L_P \left(\hat{\theta}(X_1, \dots, X_n) \right) \right] - \inf_{\theta \in \Theta} L_P(\theta) \right\} \quad (6.5)$$

其中期望是关于 X_i 以及 $\hat{\theta}$ 中的任何随机性求取的。该表达式刻画了 $\hat{\theta}$ 的（期望）risk 与 minimum risk（即假设提前知道分布 P 时所能达到的风险）之间的差异。Minimax excess risk 是基于损失 ℓ 、定义域 Θ 和分布族 $\mathcal{P}$ 定义的：

$$M_n(\Theta, \mathcal{P}, \ell) := \inf_{\hat{\theta}} \sup_{P \in \mathcal{P}} \left\{ \mathbb{E}_P \left[L_P \left(\hat{\theta}(X_1, \dots, X_n) \right) \right] - \inf_{\theta \in \Theta} L_P(\theta) \right\} \quad (6.6)$$

其中下确界是遍历所有估计器 $\theta : \mathcal{X}^n \rightarrow \Theta$ 取的，并且损失 ℓ 隐式地定义了总体损失 L_P 。





- Trivial: 使用 Bayesian 的方法

计算 maximum risk 的方法往往通过将其视为一个 Bayesian 问题以获取下界。令 $\{P_v\}$ 是以 v 为下标，以 π 为概率密度的一族分布，maximum risk 有下界

$$\sup_{P \in \mathcal{P}} \mathbb{E}_P \left[\Phi \left(\rho \left(\hat{\theta}(X_1^n), \theta(P) \right) \right) \right] \geq \sum_v \pi(v) \mathbb{E}_{P_v} \left[\Phi \left(\rho \left(\hat{\theta}(X_1^n), \theta(P_v) \right) \right) \right] \quad (6.7)$$





- 将参数估计问题转化为假设检验问题


我们考虑将参数估计问题简化为一个假设检验问题以获得下界。给定有限集 $\mathcal{V}$ ，考虑 $\{P_v\}_{v \in \mathcal{V}}$ 。这一族分布诱导出 $\{\theta(P_v)\}_{v \in \mathcal{V}}$ 。我们称这在度量 ρ 下是一个 2δ -packing，若

$$\rho(\theta(P_v), \theta(P_{v'})) \geq 2\delta, \quad v \neq v' \quad (6.8)$$

我们使用这个分布族来定义最标准的假设检验问题。首先，大自然在 $\mathcal{V}$ 中等概率选择 V 。其次，在 $V = v$ 的条件下，从 P_v^n 中采样 $X = X_1^n$ 。根据观察到的 X ，我们的目标是确定 v ，具体而言我们用 $\Psi: \mathcal{X}^n \rightarrow \mathcal{V}$ 作为检验函数。特别地，如果我们取 $\bar{P} = \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} P_v$ 为混合分布，假设检验问题就变成了根据 $\bar{P}$ 中的采样，确定随机选取的下标 V 。

由此，可以得到参数估计问题的一个经典下界：

$$\mathcal{M}_n(\theta(P), \Phi \circ \rho) \geq \Phi(\delta) \inf_{\Psi} P(\Psi(X_1, \dots, X_n) \neq V) \quad (6.9)$$





$$\mathcal{M}_n(\theta(P), \Phi \circ \rho) \geq \Phi(\delta) \inf_{\Psi} P(\Psi(X_1, \dots, X_n) \neq V)$$

证明思路如下。固定 $\hat{\theta}$ ，由于 Φ 不减，可以得到

$$\mathbb{E}[\Phi(\rho(\hat{\theta}, \theta))] \geq \mathbb{E}[\Phi(\delta) \mathbf{1}\{\rho(\hat{\theta}, \theta) \geq \delta\}] = \Phi(\delta) P(\rho(\hat{\theta}, \theta) \geq \delta) \quad (6.10)$$

令 $\theta_v = \theta(P_v)$ 。由于我们假设 $\rho(\theta_v, \theta_{v'}) \geq 2\delta$ ，当我们定义

$$\Psi(\hat{\theta}) = \arg \min_{v \in \mathcal{V}} \{\rho(\hat{\theta}, \theta_v)\} \quad (6.11)$$

时，可以得到 $\rho(\hat{\theta}, \theta_v) < \delta \Rightarrow \Phi(\hat{\theta}) = v$ 。同理， $\Phi(\hat{\theta}) \neq v \Rightarrow \rho(\hat{\theta}, \theta_v) \geq \delta$ 。于是可得：

$$\begin{aligned} \sup_P P(\rho(\hat{\theta}, \theta_v) \geq \delta) &= \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} P(\rho(\hat{\theta}, \theta_v) \geq \delta \mid V = v) \\ &\geq \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} P(\Psi(\hat{\theta}) \neq v \mid V = v) \end{aligned} \quad (6.12)$$

对所有 Ψ 取 $\inf$ 就得到了原命题的结论。



- 找假设检验问题的**错误概率**的下界 $\mathcal{M}_n(\theta(P), \Phi \circ \rho) \geq \Phi(\delta) \inf_{\Psi} P(\Psi(X_1, \dots, X_n) \neq V)$

剩下的挑战是为多元假设检验问题中的错误概率寻找下界，我们通过选择分离度 δ 来在损失 $\Phi(\delta)$ 和错误概率之间做 tradeoff。通常，人们会选择能够保证错误概率为常数的最大 δ 。为此，我们将介绍三种技术：Le Cam、Fano 和 Assouad。在此之前，我们先回顾一些定义在概率分布上的 divergence measures 之间的不等式。

由凸函数 f 定义的 f -divergence 是

$$D_f(P\|Q) = \int q(x) f\left(\frac{p(x)}{q(x)}\right) d\mu(x) \quad (6.13)$$

几种常见的 f -divergence 如下：

$$\|P - Q\|_{\text{TV}} := \sup_{A \subset \mathcal{X}} |P(A) - Q(A)| = \frac{1}{2} \int |p(x) - q(x)| d\mu(x), \quad (6.14)$$

$$d_{\text{hel}}(P, Q)^2 := \frac{1}{2} \int (\sqrt{p(x)} - \sqrt{q(x)})^2 d\mu(x), \quad (6.15)$$

$$D_{\text{kl}}(P\|Q) := \int p(x) \log\left(\frac{p(x)}{q(x)}\right) d\mu(x), \quad (6.16)$$





- Hellinger distance:

$$d_{\text{hel}}(P, Q)^2 \leq \|P - Q\|_{\text{TV}} \leq d_{\text{hel}}(P, Q) \sqrt{2 - d_{\text{hel}}(P, Q)^2} \quad (6.17)$$

- Pinsker's inequality:

$$\|P - Q\|_{\text{TV}} \leq \frac{1}{2} D_{\text{kl}}(P \parallel Q) \quad (6.18)$$

此外，关于 product distributions 和 tensorization，还有以下结果：

$$D_{\text{kl}}(P \parallel Q) = \sum_{i=1}^n D_{\text{kl}}(P_i \parallel Q_i) \quad (6.19)$$

而且由于 $d_{\text{hel}}(P, Q)^2 = 1 - \int \sqrt{dP dQ}$ ，Hellinger distance 也可以进行 tensorization：

$$d_{\text{hel}}(P, Q)^2 = 1 - \prod_{i=1}^n (1 - d_{\text{hel}}^2(P_i, Q_i)) \quad (6.20)$$

于是我们还可以得到

$$\|P^n - Q^n\|_{\text{TV}}^2 \leq \frac{1}{2} D_{\text{kl}}(P^n \parallel Q^n) = \frac{n}{2} D_{\text{kl}}(P \parallel Q) \quad (6.21)$$

$$\|P^n - Q^n\|_{\text{TV}}^2 \leq \sqrt{2} d_{\text{hel}}(P^n, Q^n) \leq \sqrt{2 - 2(1 - d_{\text{hel}}(P, Q)^2)^n} \quad (6.22)$$

上式说明，如果我们能保证 $D_{\text{kl}}(P \parallel Q) \leq \frac{1}{n}$ 或者 $d_{\text{hel}}(P, Q) \leq \frac{1}{\sqrt{n}}$ ，就可以保证 $\|P^n - Q^n\|_{\text{TV}} \leq 1 - c$ ，对某个固定的常数 $c > 0$ 。





- 可以找到指数级别的 packing


下面我们还需要回顾 packing 相关的内容。有关体积的放缩给出，如果 B 是 $\mathbb{R}^d$ 中的单位球，则

$$\left(\frac{1}{\delta}\right)^d \leq N(\delta, B, \|\cdot\|) \leq \left(1 + \frac{2}{\delta}\right)^d \quad (6.23)$$

由于 $M(\delta, B, \|\cdot\|) \geq N(\delta, B, \|\cdot\|)$ ，所以有以下推论：存在 $\mathcal{V} \subset B, |\mathcal{V}| \geq 2^d$ 满足 $\forall v \neq v' \in \mathcal{V}, \|v - v'\| \geq \frac{1}{2}$ 。

另一种常见的 packing 来自编码理论。Gilbert-Varshamov bound 指出，存在 $\mathcal{V} \subset \{-1, 1\}^d$ ， $|\mathcal{V}| \geq \exp(\frac{d}{8})$ 且

$$\|v - v'\|_1 = 2 \sum_{j=1}^d \mathbf{1}\{v_j \neq v_{j'}\} \geq \frac{d}{2} \quad (6.24)$$





- 考虑只有两个备择假设的假设检验问题

考虑只有两个备择假设的假设检验问题， V 等概率为 1 或 2。对于任何 test $\Psi: \mathcal{X} \rightarrow \{1, 2\}$ ，错误的概率是


$$P(\Psi(X) \neq V) = \frac{1}{2}P_1(\Psi(X) \neq 1) + \frac{1}{2}P_2(\Psi(X) \neq 2) \quad (6.29)$$

对于 $\mathcal{X}$ 上的任何分布 P_1, P_2 ，均有

$$\inf_{\Psi} \{P_1(\Psi(X) \neq 1) + P_2(\Psi(X) \neq 2)\} = 1 - \|P_1 - P_2\|_{\text{TV}} \quad (6.30)$$

如果 P_1 和 P_2 是等概率选择的，那么

$$\inf_{\Psi} P(\Psi(X_1, \dots, X_n) \neq V) = \frac{1}{2} - \frac{1}{2}\|P_1^n - P_2^n\|_{\text{TV}} \quad (6.31)$$





- 考虑只有两个备择假设的假设检验问题

$$\mathcal{M}_n(\theta(P), \Phi \circ \rho) \geq \Phi(\delta) \inf_{\Psi} P(\Psi(X_1, \dots, X_n) \neq V)$$

$$\inf_{\Psi} P(\Psi(X_1, \dots, X_n) \neq V) = \frac{1}{2} - \frac{1}{2} \|P_1^n - P_2^n\|_{\text{TV}}$$


结合上面的式子可以得到 minimax risk 的一个下界。对于任何 $\mathcal{P}$ 和 $P_1, P_2 \in \mathcal{P}$ 满足 $\rho(\theta(P_1), \theta(P_2)) \geq 2\delta$, 我们有

$$\mathcal{M}_n(\theta(P), \Phi \circ \rho) \geq \Phi(\delta) \left[\frac{1}{2} - \frac{1}{2} \|P_1^n - P_2^n\|_{\text{TV}} \right] \quad (6.32)$$

如果我们能选择适当的 P_1, P_2 , 使得 $\|P_1^n - P_2^n\|_{\text{TV}} \leq \frac{1}{2}$, 只要 $\rho(\theta(P_1), \theta(P_2)) \geq 2\delta$, 就有 $\mathcal{M}_n \geq \frac{1}{4}\Phi(\delta)$ 。类似的例子可以用在 Bernoulli mean estimation 上, 得到

$$\mathcal{M}_n(\text{Bernoulli}([-1, 1]), (\cdot)^2) \geq \frac{1}{24n} \text{ or } \frac{1}{16n} \quad (6.33)$$

这些例子说明我们可以在均方误差下以与 $\frac{1}{n}$ 成正比的速率来估计 θ 。





- 如果备择假设的数量 > 2


Fano 的方法可以适用于 $|\mathcal{V}| > 2$ 的场景。先从 Fano's InE 出发：对于任意的 Markov chain $V \rightarrow X \rightarrow \hat{V}$ ，我们有

$$h_2(P(\hat{V} \neq V)) + P(\hat{V} \neq V) \log(|\mathcal{V}| - 1) \geq H(V | \hat{V}) \quad (6.34)$$

其中 $h_2(p) = -p \log p - (1-p) \log(1-p)$ 。直观理解，RHS 是观测到 $\hat{V}$ 后真实值 V 剩下的不确定性，LHS 的第一项是是否出错的信息熵，第二项是如果出错是哪一个错了的信息熵。

推论：如果 V 在 $\mathcal{V}$ 上服从均匀分布，对于任意 Markov chain $V \rightarrow X \rightarrow \hat{V}$ ，

$$P(\hat{V} \neq V) \geq 1 - \frac{I(V; X) + \log 2}{\log |\mathcal{V}|} \quad (6.35)$$





- 如果备择假设的数量 > 2


于是，如果 $\{\theta(P_v)\}_{v \in \mathcal{V}}$ 是一个 2δ -packing，并且 V is uniform on $\mathcal{V}$ ，采样 $X \sim P_v$ ，可得

$$\mathcal{M}(\theta(\mathcal{P}); \Phi \circ \rho) \geq \Phi(\delta) \left(1 - \frac{I(V; X) + \log 2}{\log |\mathcal{V}|} \right) \quad (6.36)$$

我们把下界视为关于 δ 的函数。当 $\delta \rightarrow 0$ 时， P_v 会更加接近， $I(V; X)$ 会减小，假设检验问题会变得更难。所以我们希望将 $\theta(P_v)$ 设定为关于 δ 的函数，找到最大的 δ 使得

$$\frac{I(V; X) + \log 2}{\log |\mathcal{V}|} \leq \frac{1}{2} \quad (6.37)$$

也就是让错误概率成为一个常数，使得 minimax lower bound 至少达到 $\frac{\Phi(\delta)}{2}$ 。





- 如何处理互信息?


$$\frac{I(V; X) + \log 2}{\log |\mathcal{V}|} \leq \frac{1}{2}$$

Mutual Information and KL-divergence 用 KL 散度表达互信息:

$$I(V; X) = D_{\text{kl}}(P_{X,V} \parallel P_X \times P_V) \quad (6.38)$$

在之前的设定中, V 是根据先验分布 π (为了简便只考虑其为离散分布) 取出的。令 P_v 表示 $V = v$ 时的分布, 则 X 是从 $\bar{P} = \sum_v \pi(v) P_v$ 分布中采样的, 于是可得

$$I(V; X) = \sum_v \pi(v) D_{\text{kl}}(P_v \parallel \bar{P}) \quad (6.39)$$





The Local Fano Method 在 uniform setting 下, 根据 $\log$ 的凸性, 有

$$I(V; X) = \frac{1}{|\mathcal{V}|} \sum_{v \in \mathcal{V}} D_{\text{kl}}(P_v \parallel \bar{P}) \leq \frac{1}{|\mathcal{V}|^2} \sum_{v, v'} D_{\text{kl}}(P_v \parallel P_{v'}) \quad (6.40)$$

在 local Fano method 中, 我们构造一个分布族 P_v 来定义一个 2δ -packing, 即对于所有 $v \neq v'$, 均有 $\rho(\theta(P_v), \theta(P_{v'})) \geq 2\delta$, 但同时它还额外满足一个 uniform upper bound:

$$D_{\text{kl}}(P_v \parallel P_{v'}) \leq \kappa^2 \delta^2 \quad (6.41)$$

其中 $\kappa > 0$ 是一个固定的、依赖于具体问题的常数。如果上式成立, 那么只要我们能找到一个 local packing $\mathcal{V}$ 使得


$$\log |\mathcal{V}| \geq 2(\kappa^2 \delta^2 + \log 2), \quad (6.42)$$

我们就可以保证 Equation (6.37) 成立, 从而得到 minimax lower bound:

$$M(\theta(\mathcal{P}), \Phi \circ \rho) \geq \frac{1}{2} \Phi(\delta). \quad (6.43)$$

其困难之处在于如何构造 $\mathcal{V}$, 使得能够选择合适的 δ 来获得 sharp lower bounds。

$$\frac{I(V; X) + \log 2}{\log |\mathcal{V}|} \leq \frac{1}{2}$$





Constructing Local Packings 使用 Fano 方法的主要困难在于构造所谓的 local packing。典型的方法是构造一个固定集合（例如在向量空间 $\mathbb{R}^d$ 中）的 packing $\mathcal{V}$ ，具有恒定的半径和恒定的距离。然后我们按 $\delta > 0$ 对填充的元素进行缩放，这保持了基数 $|\mathcal{V}|$ 不变，但允许我们在 packing 的分离度和一致散度界中选择 δ 。例如，Equation (6.24) 表明，我们可以构造具有固定半径、基数满足 $\log|\mathcal{V}| \gtrsim d$ 的指数级 packing，从而给出对维度的依赖关系。


下面我们还需要回顾 packing 相关的内容。有关体积的放缩给出，如果 B 是 $\mathbb{R}^d$ 中的单位球，则

$$\left(\frac{1}{\delta}\right)^d \leq N(\delta, B, \|\cdot\|) \leq \left(1 + \frac{2}{\delta}\right)^d \quad (6.23)$$

由于 $M(\delta, B, \|\cdot\|) \geq N(\delta, B, \|\cdot\|)$ ，所以有以下推论：存在 $\mathcal{V} \subset B, |\mathcal{V}| \geq 2^d$ 满足 $\forall v \neq v' \in \mathcal{V}, \|v - v'\| \geq \frac{1}{2}$ 。

另一种常见的 packing 来自编码理论。Gilbert-Varshamov bound 指出，存在 $\mathcal{V} \subset \{-1, 1\}^d$ ， $|\mathcal{V}| \geq \exp(\frac{d}{8})$ 且

$$\|v - v'\|_1 = 2 \sum_{j=1}^d \mathbf{1}\{v_j \neq v_{j'}\} \geq \frac{d}{2} \quad (6.24)$$





我们通过正态分布的均值估计的例子来说明这个技术。考虑 $\mathcal{N}_d = \{N(\theta, \sigma^2 I_{d \times d}) \mid \theta \in \mathbb{R}^d\}$; 我们希望在均方误差下估计给定分布 $P \in \mathcal{N}_d$ 的均值 $\theta = \theta(P)$, 即损失为 $\|\hat{\theta} - \theta\|_2^2$ 。令 $\mathcal{V}$ 为单位 ℓ_2 -球的 $\frac{1}{2}$ -packing, 其基数至少为 2^d 。


现在构造 local packing。固定 $\delta > 0$, 并且对于每个 $v \in \mathcal{V}$, 设定 $\theta_v = \delta v \in \mathbb{R}^d$ 。那么对于 $\mathcal{V}$ 中每一个不同的对 v, v' , 我们有

$$\|\theta_v - \theta_{v'}\|_2 = \delta \|v - v'\|_2 \geq \frac{\delta}{2} \quad (6.44)$$

此外, 我们注意到对于这样的对, 同样有 $\|\theta_v - \theta_{v'}\|_2 \leq 2\delta$ 。应用 Equation (6.36) 的 Fano minimax 界, 我们发现 (给定 $X_i \stackrel{\text{i.i.d.}}{\sim} P$)

$$M_n(\theta(\mathcal{N}_d), \|\cdot\|_2^2) \geq \left(\frac{1}{2} \cdot \frac{\delta}{2}\right)^2 \left(1 - \frac{I(V; X_1^n) + \log 2}{\log |\mathcal{V}|}\right) = \frac{\delta^2}{16} \left(1 - \frac{I(V; X_1^n) + \log 2}{d \log 2}\right) \quad (6.45)$$

$$\mathcal{M}(\theta(\mathcal{P}); \Phi \circ \rho) \geq \Phi(\delta) \left(1 - \frac{I(V; X) + \log 2}{\log |\mathcal{V}|}\right)$$





现在注意到, 对于任意一对 v, v' , 如果 P_v 是正态分布 $N(\theta_v, \sigma^2 I_{d \times d})$, 我们有

$$D_{\text{kl}}(P_v^n \parallel P_{v'}^n) = n \cdot D_{\text{kl}}(N(\delta v, \sigma^2 I_{d \times d}) \parallel N(\delta v', \sigma^2 I_{d \times d})) = n \cdot \frac{\delta^2}{2\sigma^2} \|v - v'\|_2^2 \quad (6.46)$$

由于 $\|v - v'\|_2 \leq 2$, 我们得到了具有 $\kappa^2 = \frac{2n}{\sigma^2}$ 的 KL 散度界。

$$D_{\text{kl}}(P_v \parallel P_{v'}) \leq \kappa^2 \delta^2$$

结合我们的推导, 我们得到 minimax bound:


$$M_n(\theta(\mathcal{N}_d), \|\cdot\|_2^2) \geq \frac{\delta^2}{16} \left(1 - \frac{2n\delta^2/\sigma^2 + \log 2}{d \log 2} \right) \quad (6.47)$$

然后通过取 $\delta^2 = \frac{d\sigma^2 \log 2}{8n}$, 我们发现

$$1 - \frac{2n\delta^2/\sigma^2 + \log 2}{d \log 2} = 1 - \frac{1}{d} - \frac{1}{4} \geq \frac{1}{4} \quad (6.48)$$

基于 $d \geq 2$ 的假设, 可得:

$$M_n(\theta(\mathcal{N}_d), \|\cdot\|_2^2) \geq \frac{d\sigma^2 \log 2}{128n} \cdot \frac{1}{4} \gtrsim \frac{d\sigma^2}{n} \quad (6.49)$$





- 为什么要研究 minimax risk

理解统计（参数）估计的性能极限；

- 如何得到 minimax risk 的下界

将参数估计问题转化为假设检验问题，通过构造参数空间上的 2δ -packing，在损失函数 $\Phi(\delta)$ 与假设检验的错误概率之间做 Trade-off；

- Le Cam's Method

针对仅有两个备择假设的检验问题，利用 TV 距离得出下界；

- Fano's Method

针对多个备择假设的场景，利用 Fano 不等式将错误概率与互信息、KL 散度联系起来；

- Local Fano Method

构造既满足距离下界又满足 KL 散度一致上界的 local packing。

